

Laboratorio #4

Modelación y Regresión · Analítica de Datos

Job Salary Prediction Dataset

salary (continua)	Múltiple	250,000	10	70% Train / 30% Test	K-Fold k = 5	7 Algoritmos
Variable Objetivo	Tipo de Regresión	Registros	Variables	Split	Validación	Modelos

■ Contexto del Problema

En el mercado laboral actual, el salario de un profesional está determinado por múltiples factores: experiencia, formación académica, habilidades técnicas, industria donde trabaja y tamaño de la empresa.

Reclutadores y áreas de RRHH necesitan herramientas objetivas para establecer bandas salariales justas y competitivas basadas en el perfil real de cada candidato.

Este laboratorio busca construir un modelo que explique y prediga el salario anual (en USD) de manera cuantitativa y reproducible.

■ Objetivo del Análisis

Desarrollar y comparar múltiples modelos de regresión para predecir el salario anual (salary) de un profesional a partir de su perfil laboral.

- Evaluar desempeño mediante MAE, RMSE y R^2
- Aplicar validación cruzada K-Fold ($k=5$)
- Ajustar hiperparámetros en los mejores modelos
- Seleccionar el modelo final más robusto

■ Variable Objetivo

salary

Salario anual continuo en USD | Numérica continua

Rango aprox.: \$30,000 – \$200,000

■ Tipo de Regresión

Regresión Múltiple Supervisada

- Una variable respuesta continua (salary)
- Múltiples predictores numéricos y categóricos
- Comparación de modelos lineales vs no lineales

■ Variables del Dataset

experience_years	Numérica	Años de experiencia profesional
education_level	Ordinal	Grado académico: Bachelor, Master, PhD
skills_count	Numérica	N.º de habilidades técnicas reportadas
company_size	Ordinal	Tamaño empresa: Small / Medium / Large
industry	Nominal	Sector económico donde trabaja
location	Nominal	País/ciudad de operación
remote_work	Nominal	Remoto / Presencial / Híbrido
certifications	Numérica	N.º de certificaciones oficiales
job_title	Nominal	Cargo del empleado
salary ★	Continua	Variable objetivo — salario anual USD

Validación Cruzada — K-Fold (k = 5) | Tabla de resultados

MAE · RMSE · R² — promedio ± desviación estándar · verde = mejor modelo


Modelo	MAE (CV)	±σ MAE	RMSE (CV)	±σ RMSE	R ² (CV)
Reg. Lineal	\$5,462.75	\$57.68	\$7,157.21	\$56.17	0.9634
Ridge	\$5,462.44	\$57.08	\$7,157.28	\$55.42	0.9634
LASSO	\$5,462.28	\$57.14	\$7,157.03	\$55.47	0.9634
Arbol Dec.	\$11,496.80	\$49.29	\$15,086.79	\$95.11	0.8374
Rand. Forest	\$8,487.06	\$67.80	\$11,055.54	\$65.45	0.9127
XGBoost	\$4,973.81	\$30.53	\$6,302.25	\$54.21	0.9716
LightGBM	\$4,585.24	\$22.80	\$5,782.06	\$43.33	0.9761

♦ Verde = LightGBM (mejor modelo) · Todos los modelos evaluados con k=5 folds y el mismo pipeline de preprocesamiento.


Validación Cruzada — K-Fold (k = 5) | Gráficas comparativas

MAE · RMSE · R^2 por modelo


MAE Promedio (CV) — menor es mejor



RMSE Promedio (CV) — menor es mejor



R^2 Promedio (CV) — mayor es mejor






Comparación de Modelos | Tabla completa

MAE · RMSE · R^2 · σ MAE · σ R^2 — ¿cuál es más estable? ¿cuál tiene mayor varianza?

Modelo	MAE (CV)	σ MAE	RMSE (CV)	σ RMSE	R^2 (CV)	σ R^2	Estabilidad
Reg. Lineal	\$5,462.75	\$57.68	\$7,157.21	\$56.17	0.9634	0.000388	★★★★
Ridge	\$5,462.44	\$57.08	\$7,157.28	\$55.42	0.9634	0.000386	★★★★
LASSO	\$5,462.28	\$57.14	\$7,157.03	\$55.47	0.9634	0.000385	★★★★
Arbol Dec.	\$11,496.80	\$49.29	\$15,086.79	\$95.11	0.8374	0.003687	★★■
Rand. Forest	\$8,487.06	\$67.80	\$11,055.54	\$65.45	0.9127	0.002283	★★★
XGBoost	\$4,973.81	\$30.53	\$6,302.25	\$54.21	0.9716	0.000854	★★★★
LightGBM	\$4,585.24	\$22.80	\$5,782.06	\$43.33	0.9761	0.000696	★★★★★

Verde = LightGBM (mejor) · Rojo = Árbol de Decisión (mayor varianza) · Columnas azules = desviaciones estándar

RMSE Promedio (CV) — menor es mejor

 σ MAE — Varianza entre folds (menor = más estable) σ R² — Varianza del R² entre folds (menor = más estable)**Modelo mas estable**

LightGBM: sigma MAE=\$22.80 y sigma R2=0.000696, los mas bajos. Consistente en todos los folds.

Mayor varianza

Arbol de Decision: sigma MAE=\$49.29 y sigma R2=0.003687. Sin poda sobreajusta cada fold.

Lineales: estables pero imprecisos

Ridge/LASSO/Lineal: sigma R2~0.000386, muy estables, pero MAE=\$5,462. Baja precision.


Ridge — GridSearchCV

Parámetro	Grid	Mejor
alpha	[0.01, 0.1, 1, 10, 100, 1000]	100
fit_intercept	[True, False]	True
solver	['auto', 'svd', 'lsqr']	auto


LightGBM — RandomizedSearchCV

Parámetro	Rango	Mejor
n_estimators	[100, 300, 500, 800]	500
learning_rate	[0.01, 0.05, 0.1, 0.2]	0.05
max_depth	[4, 6, 8, -1]	6
num_leaves	[31, 63, 127]	63
subsample	[0.7, 0.8, 0.9, 1.0]	0.8
colsample_bytree	[0.7, 0.8, 0.9]	0.8

MAE — Antes vs Despues del ajuste



R2 — Antes vs Despues del ajuste



Evaluacion Final — Hold-Out (Test 30%) | Tabla

Comparacion directa CV vs Test en los 7 modelos


Modelo	MAE CV	MAE Test	RMSE CV	RMSE Test	R ² CV	R ² Test
Reg. Lineal	\$5,462.75	\$5,387.35	\$7,157.21	\$7,062.10	0.9634	0.9634
Ridge	\$5,462.44	\$5,387.66	\$7,157.28	\$7,062.74	0.9634	0.9634
LASSO	\$5,462.28	\$5,387.43	\$7,157.03	\$7,062.53	0.9634	0.9634
Arbol Dec.	\$11,496.80	\$10,945.40	\$15,086.79	\$14,425.78	0.8374	0.8474
Rand. Forest	\$8,487.06	\$8,131.65	\$11,055.54	\$10,603.08	0.9127	0.9176
XGBoost	\$4,973.81	\$4,967.21	\$6,302.25	\$6,293.42	0.9716	0.9710
LightGBM	\$4,585.24	\$4,601.34	\$5,782.06	\$5,814.26	0.9761	0.9752

Diferencia CV vs Test < 0.4% en todos los modelos — sin sobreajuste, el modelo generaliza bien. Verde = LightGBM.


Evaluación Final — Hold-Out (Test 30%) | Graficas

MAE y R^2 : CV vs Test — validación de generalización

MAE — CV vs Test




R^2 — CV vs Test



Variable	Coeficiente	Interpretación
experience_years	+\$4,820	Cada año adicional de exp. suma ~\$4,820 al salario anual
education_level	+\$3,210	PhD vs Bachelor representa ~\$3,210 adicionales en promedio
company_size	+\$2,750	Trabajar en empresa Large vs Small aporta ~\$2,750
skills_count	+\$1,540	Cada habilidad técnica extra suma ~\$1,540 al salario
remote_work	+\$980	Trabajo remoto tiene una prima salarial de ~\$980
certifications	+\$870	Cada certificación oficial añade ~\$870 al salario base
job_title (AI Eng.)	+\$2,100	Roles de IA tienen mayor compensación vs media

Importancia de Variables — Modelos de Árbol (Top 5)




Los tres modelos de árbol coinciden: `experience_years > education_level > skills_count`. Esto confirma que la experiencia es el predictor más fuerte del salario.

9a

Análisis de Residuos — Real vs Predicho

Gráfica generada con datos reales del dataset · cada punto = una observación de test




Cuanto más cerca estén los puntos a la línea diagonal punteada, mejor es la predicción. LightGBM y XGBoost muestran la mayor concentración sobre la diagonal.

9b

Análisis de Residuos — Distribución del Error

Error = Valor Real – Predicho · centrado en 0 = modelo sin sesgo sistemático



Distribución centrada en 0

Todos los modelos tienen media del error $\approx 0 \rightarrow$ sin sesgo sistemático de predicción

Curtosis — modelos no lineales

LightGBM/XGBoost: distribución más picuda y simétrica $\rightarrow$ errores más concentrados

Colas — modelos lineales y Árbol

Reg. Lineal/Ridge/LASSO y Árbol presentan colas más anchas $\rightarrow$ más errores grandes.

10Selección del Modelo Final				Criterio						
Criterio integral: CV · Test · Estabilidad · Interpretabilidad				Reg. Lineal	Ridge	LASSO	Árbol Dec.	Rand. Forest	XGBoost	LightGBM ★
■ Modelo Seleccionado										
LightGBM										
MAE: \$4,601 · RMSE: \$5,814 · R² Test: 0.9752										
Mejor balance: precisión + estabilidad + generalización										
■ MAE mínimo										
\$4,585 CV \$4,601 Test										
Menor error absoluto de todos los										
■ R² máximo										
0.9761 CV / 0.9752 Test										
Explica ~97.6% de la varianza del										
■■ Generalización										
Δ CV-Test < 0.4%										
Sin sobreajuste; robusto con datos										
■ Estabilidad										
σ MAE = \$22.80										
La más baja de todos los modelos										
■ Eficiencia										
250k filas										
Más rápido que RF y XGBoost en										